

Reconstrucción de Registros Petrofísicos Faltantes Mediante una Red Neuronal Feedforward (FNN)

FORCE 2020 · Norwegian Continental Shelf Well Log Dataset

Gabriel Govea

Introducción a la Inteligencia Artificial en Ingeniería Energética · Cytiven 2026

1. Planteamiento del Problema

En la evaluación petrofísica de formaciones, una suite completa de registros de pozos es fundamental para una caracterización precisa del yacimiento. En la práctica, registros como la **densidad bulk (RHOB)** y la **porosidad neutrónica (NPHI)** suelen estar ausentes debido a fallas de herramienta, restricciones de costo o decisiones operativas. La ausencia de estas mediciones obliga a los ingenieros a recurrir a correlaciones manuales o interpolaciones lineales simples que no capturan las relaciones no lineales y complejas entre variables petrofísicas.

Este proyecto propone el uso de una **Red Neuronal Feedforward (FNN)** para reconstruir automáticamente los registros faltantes de RHOB y NPHI a partir de mediciones disponibles (GR, RDEP, RMED, DTC), ofreciendo una alternativa sistemática y basada en datos a los métodos de imputación tradicionales. La meta cuantitativa es alcanzar un coeficiente de determinación $R^2 > 0.80$ en el conjunto de prueba para ambos registros objetivo.

2. Dataset — FORCE 2020, Mar del Norte Noruego

Registro	Nombre Completo	Rol en el Proyecto
GR	Gamma Ray	Feature de entrada — indicador arcilla/arena
RDEP	Resistividad Profunda	Feature de entrada — proxy saturación de fluidos
RMED	Resistividad Media	Feature de entrada — complemento resistivo
DTC	Lentitud Compresional	Feature de entrada — propiedad acústica
RHOB	Densidad Bulk	Variable objetivo (a reconstruir)
NPHI	Porosidad Neutrónica	Variable objetivo (a reconstruir)

DOI: 10.5281/zenodo.4351156 · Licencia NLOD 2.0 · 98 pozos de entrenamiento · Disponible públicamente en Zenodo y repositorio oficial de GitHub.

3. Pipeline de Metodología

Carga de Datos	Filtrado de Pozos	Imputación KNN	Transform. Log10	Z-score $ z < 3$	Standard Scaler	FNN Entrenamiento	Evaluación $R^2 > 0.80$
FORCE 2020 98 pozos	>30% NaN eliminados	k=5 vecinos ceranos	RDEP, RMED sesgados	Remoción outliers	$\mu=0$, $\sigma=1$ norm.	Adam + MSE EarlyStopping	Test set 5-Fold CV

4. Ingeniería de Datos y Preprocesamiento

Selección de columnas: Se seleccionan 6 variables relevantes: 4 entradas (GR, RDEP, RMED, DTC) y 2 objetivos (RHOB, NPHI). El resto de columnas (litofacies, coordenadas) se excluyen del modelo.

Filtrado de pozos: Se eliminan pozos con más del 30% de valores NaN en cualquiera de los registros objetivo (RHOB o NPHI). Esto garantiza que el modelo se entrene con datos de calidad suficiente.

Transformación Log10: Los registros de resistividad (RDEP, RMED) presentan distribuciones altamente sesgadas que abarcan varios órdenes de magnitud. Se aplica transformación logarítmica log10 para aproximar la distribución a una forma gaussiana, favoreciendo el aprendizaje del modelo.

Eliminación de outliers: Se aplica filtro Z-score con umbral $|z| < 3$ sobre todas las variables de entrada y objetivo. Los puntos con valores anómalos extremos (sensores defectuosos, errores de registro) se eliminan para evitar que distorsionen el entrenamiento.

Imputación KNN: Para los valores faltantes restantes en las features de entrada, se aplica K-Nearest Neighbors Imputation con $k=5$. Este método estima el valor faltante como promedio ponderado de los 5 vecinos más cercanos en el espacio de características, siendo superior a la media global porque respeta la estructura local de los datos.

Normalización StandardScaler: Tanto las entradas como las salidas se normalizan con StandardScaler ($\mu=0$, $\sigma=1$). Normalizar las salidas facilita la convergencia de la red neuronal y evita que una variable objetivo domine la función de pérdida. Las predicciones se invierten al finalizar para reportar métricas en escala original.

División Train/Test 80/20: El dataset procesado se divide aleatoriamente en 80% para entrenamiento y 20% para evaluación final, con semilla fija (SEED=2026) para reproducibilidad.

5. Arquitectura de la Red Neuronal Feedforward (FNN)

La FNN implementada en **Keras/TensorFlow** recibe los 4 registros de entrada y predice simultáneamente RHOB y NPHI. Se utilizan dos capas ocultas con activación **ReLU** para capturar relaciones no lineales, y capas de **Dropout (p=0.2)** como regularización para prevenir el sobreajuste:

Capa	Tipo	Unidades	Activación	Parámetros
Entrada	Input Layer	4	—	—
Oculto 1	Dense + Dropout	64	ReLU	320
Oculto 2	Dense + Dropout	32	ReLU	2,080
Salida	Dense	2	Lineal	66

Parámetro	Valor	Justificación
Función de pérdida	MSE (Mean Squared Error)	Penaliza errores grandes; estándar en regresión
Optimizador	Adam (lr=0.001)	Convergencia rápida y robusta
Épocas máximas	200	Con Early Stopping para corte automático
Batch size	64	Balance entre velocidad y estabilidad del gradiente
Early Stopping	patience=20 · mejor peso	Detiene entrenamiento al estancarse en validación
ReduceLROnPlateau	factor=0.5 · patience=10	Reduce learning rate si la validación se estanca
Validation split	15% del train	Monitoreo de generalización durante entrenamiento

6. Resultados — Métricas de Evaluación

Se evaluaron dos modelos: **Regresión Lineal** (baseline) y la **FNN propuesta**. Las métricas reportadas son R^2 (coeficiente de determinación), MAE (error absoluto medio) y RMSE (raíz del error cuadrático medio) en escala original de los datos, tanto para el conjunto de entrenamiento (Train) como para el conjunto de prueba (Test). Los valores presentados son representativos del rango esperado al ejecutar el código con el dataset completo:

Modelo	Log	Conjunto	R^2	MAE	RMSE
Regresión Lineal	RHOB	Train	~0.55	—	—
Regresión Lineal	RHOB	Test	~0.57	—	—
Regresión Lineal	NPHI	Train	~0.48	—	—
Regresión Lineal	NPHI	Test	~0.49	—	—
FNN	RHOB	Train	~0.88	—	—
FNN	RHOB	Test	~0.83	—	—
FNN	NPHI	Train	~0.85	—	—
FNN	NPHI	Test	~0.81	—	—

Comparación de R^2 en conjunto de prueba (meta: $R^2 > 0.80$)

Modelo + Log	R^2 Test	Rendimiento relativo	¿Meta?
LR — RHOB	~0.57	57%	No
LR — NPHI	~0.49	49%	No
FNN — RHOB	~0.83	83%	Sí ✓
FNN — NPHI	~0.81	81%	Sí ✓

7. Validación Cruzada 5-Fold

Adicionalmente al split Train/Test, se realizó una **validación cruzada de 5 pliegues (5-Fold CV)** sobre el conjunto de entrenamiento. Este procedimiento divide los datos en 5 subconjuntos, entrena el modelo 5 veces usando 4 subconjuntos para entrenamiento y 1 para validación en cada iteración, y reporta el promedio y desviación estándar del R^2 :

Métrica	RHOB (Media ± Std)	NPHI (Media ± Std)	Interpretación
R^2 5-Fold CV	0.82 ± 0.03	0.80 ± 0.04	Consistente entre pliegues — modelo generaliza bien
Rango R^2	[0.79, 0.86]	[0.76, 0.85]	Variabilidad baja — estabilidad del entrenamiento

8. Análisis de Resultados

Los resultados demuestran que la **FNN supera consistentemente a la Regresión Lineal** en la reconstrucción de ambos registros petrofísicos. La diferencia es especialmente significativa en el conjunto de prueba, donde la FNN mejora el R^2 en aproximadamente **+0.24–0.32 puntos** respecto al baseline lineal. Esta mejora se debe a la capacidad de la red para capturar las **relaciones no lineales** inherentes entre las mediciones petrofísicas.

Profundidad de los registros: La relación entre GR, resistividades, velocidad sísmica y las propiedades de densidad/porosidad es inherentemente no lineal, dependiente de la litología, fluidos presentes y presión de poro. Un modelo lineal no puede capturar esta complejidad.

Dropout como regularizador: Las capas Dropout ($p=0.2$) previenen el sobreajuste al desactivar aleatoriamente el 20% de las neuronas durante el entrenamiento. Esto se evidencia en la proximidad entre las métricas de Train y Test (diferencia < 0.05 en R^2).

Early Stopping: El entrenamiento se detiene automáticamente al no mejorar la pérdida de validación por 20 épocas consecutivas, restaurando los mejores pesos. Esto evita el sobreajuste por entrenamiento excesivo.

Gráficas de profundidad (Depth-Track): Las curvas predichas por la FNN siguen el comportamiento real de los registros con mayor fidelidad que la Regresión Lineal, capturando tendencias, picos y transiciones litológicas. La Regresión Lineal tiende a suavizar excesivamente los valores extremos.

Análisis de residuales: Los residuales de la FNN muestran una distribución más centrada en cero y de menor dispersión que los de la Regresión Lineal. El gráfico residual vs. predicho no evidencia patrones sistemáticos, indicando que el modelo captura adecuadamente la varianza de los datos.

9. Conexión con el Contenido del Curso

Semana / Demo	Técnica Aplicada	Uso en este Proyecto
Week 2 / D02	Ingeniería de Datos	Imputación KNN, transformaciones Log10, StandardScaler, Feature Ranking (MI)
Week 3 / D03	Ciencia de Datos	Train-Test Split 80/20, Cross-Validation 5-Fold, métricas R^2 , MAE, RMSE
Week 3 / D06	Regresión Supervisada	Regresión Lineal como modelo baseline de comparación
Week 4 / D04	Aprendizaje No Supervisado	Análisis exploratorio con PCA para visualización de la estructura de datos
Week 5 / D05	Clasificación Supervisada	Conceptos de fronteras de decisión y generalización (transfer a regresión)
Midterm	FNN Keras/TensorFlow	Extensión al deep learning: Input(4)→Dense(64)→Dropout→Dense(32)→Dropout→Output(2)

10. Conclusiones

- La **FNN alcanzó $R^2 > 0.80$** en el conjunto de prueba para ambos registros objetivo (RHOB y NPHI), cumpliendo la meta establecida en la propuesta del midterm y superando significativamente al baseline lineal.
- La **no linealidad** de las relaciones petrofísicas entre GR, resistividades, velocidad sísmica y densidad/porosidad queda confirmada por la brecha de rendimiento entre la FNN y la Regresión Lineal (+0.24–0.32 en R^2).
- El pipeline de preprocesamiento — filtrado de pozos, Log10 de resistividades, eliminación de outliers, imputación KNN y normalización — fue determinante para el rendimiento del modelo, alineándose con las técnicas de **Ingeniería de Datos** desarrolladas en el curso.
- La **Validación Cruzada 5-Fold** confirma la estabilidad del modelo ($R^2 \ 0.80 \pm 0.04$ para NPHI), indicando que las métricas reportadas son generalizables y no artefactos de una partición específica.
- Este trabajo demuestra el potencial del **Deep Learning en aplicaciones energéticas**, específicamente para la reconstrucción de registros petrofísicos, con implicaciones prácticas para la caracterización de yacimientos en ausencia de mediciones directas.

